
Syllabus

Marco Teran^{1,2}

¹Deep Learning y Series de tiempo

²Escuela de Ciencias exactas e Ingeniería

This course offers a detailed introduction to Deep Learning, covering a wide range of topics including data preparation, exploration and visualization, handling imbalanced classes, dimensionality reduction, regularization, ensemble algorithms, unsupervised learning, neural networks and MLP, convolutional networks and applications in images, recurrent neural networks, and time series. Students will learn to manipulate and preprocess data, select and adjust models, and evaluate model accuracy using techniques such as backtesting and evaluation metrics.

1. Introducción

Este curso de **Deep Learning** se enfoca en proporcionar a los estudiantes una comprensión sólida de los fundamentos de la teoría y aplicación del Deep Learning. Los estudiantes aprenderán cómo procesar datos, trabajar con problemas de clases desbalanceadas, reducir la dimensionalidad, aplicar técnicas de regularización y utilizar diferentes algoritmos de ensamble y aprendizaje no supervisado. El curso también se enfoca en las redes neuronales, cubriendo MLP, redes convolucionales y neuronales recurrentes. Además, los estudiantes aprenderán a trabajar con series de tiempo y aplicar modelos específicos a este tipo de datos.

- **Enfoque teórico y práctico:** los estudiantes aprenderán los fundamentos teóricos de **Deep Learning**, pero también aplicarán lo aprendido a través de casos de estudio y proyectos prácticos.
- **Profundidad en redes neuronales:** el curso cubre una amplia variedad de tipos de redes neuronales,

lo que permite a los estudiantes explorar diferentes aplicaciones y entender cómo funcionan.

- **Prácticas con herramientas populares:** los estudiantes trabajarán con herramientas y bibliotecas populares en el mundo del Deep Learning, como ScikitLearnd, Tensorflow y Keras.

2. Objetivos

2.1. Objetivos general del curso

Aprender a aplicar técnicas y algoritmos de Deep Learning para resolver problemas complejos de clasificación, regresión y predicción en diferentes campos, con énfasis en imágenes, series de tiempo y datos no estructurados.

2.2. Objetivos específicos del curso

Al terminar el curso, los estudiantes deben estar en capacidad de:

- Comprender los conceptos fundamentales del Deep Learning y cómo se diferencia del aprendizaje automático convencional.
- Adquirir habilidades para preparar, explorar, preprocesar y visualizar diferentes tipos de datos, incluyendo datos desbalanceados, imágenes y series de tiempo.
- Conocer las técnicas de reducción de dimensionalidad, regularización y creación de nuevas características para mejorar la calidad de los datos de entrada y evitar problemas de overfitting.
- Familiarizarse con diferentes algoritmos de aprendizaje supervisado, incluyendo máquinas de vectores

de soporte, árboles de decisión y redes neuronales multicapa, y aprender a ajustar sus hiperparámetros.

- Conocer los fundamentos del aprendizaje no supervisado, incluyendo clustering y reducción de la dimensionalidad, y aplicarlos a problemas de segmentación y visualización de datos.
- Aprender a diseñar, entrenar y evaluar redes neuronales convolucionales y recurrentes para la clasificación y predicción de imágenes y series de tiempo, y conocer las técnicas avanzadas de transfer learning y aumentación de datos para mejorar su rendimiento.

3. Contenido

1. Introducción a Deep Learning
 - 1.1. Preparación de datos
 - 1.2. Exploración de datos
 - 1.3. Preprocesamiento de datos
 - 1.4. Visualización de datos
2. Clases desbalanceadas
 - 2.1. Undersampling
 - 2.2. Oversampling
 - 2.3. Smote
 - 2.4. Weighted samples
3. Creación de nuevas características
4. Convertir problemas de regresión en clasificación
5. Reducción de la dimensionalidad: PCA
6. Regularización L1 y L2
7. Máquinas con Vectores de Soporte (SVM)
 - 7.1. Hard Margin vs Soft Margin
8. Algoritmos de ensamble:
 - 8.1. Bagging vs Boosting
 - 8.2. Random Forest
 - 8.3. XGboost
9. Aprendizaje no supervisado:
 - 9.1. Distancias
 - 9.2. Clustering jerárquico
 - 9.3. Clustering no jerárquico: K-means
10. Redes neuronales y MLP
 - 10.1. Perceptrón
 - 10.2. Perceptrón multicapa
 - 10.3. Algoritmo de Propagación hacia atrás
 - 10.4. Red Feed Forward
 - 10.5. Funciones de activación
 - 10.6. Funciones de costo
 - 10.7. Regularización
 - 10.7.1. L1 y L2
 - 10.7.2. Dropout
 - 10.8. Validación - Testeo
 - 10.9. Ajuste de hiperparámetros
 - 10.10. Tipos de MLP:
 - 10.10.1. Clasificación binaria
 - 10.10.2. Multiclasificación
 - 10.10.3. Regresión
11. Redes convolucionales y aplicaciones a imágenes
 - 11.1. Convolución
 - 11.2. Kernels
 - 11.3. MaxPool y AvgPool
 - 11.4. Imágenes aumentadas
 - 11.5. Transfer learning
12. Redes neuronales Recurrentes:
 - 12.1. LSTM
13. Series de tiempo:
 - 13.1. Introducción a series de tiempo
 - 13.2. Indexado en series de tiempo
 - 13.3. Manipulación y visualización
 - 13.4. Preprocesamiento
 - 13.4.1. Enventanado
 - 13.4.2. Retrasos
 - 13.4.3. Remuestreo
 - 13.4.4. Autocorrelaciones
 - 13.5. Ruido Blanco y Random Walk
 - 13.6. Estructura de una serie de tiempo
 - 13.6.1. Level, Trend, Seasonality, Noise
 - 13.6.2. Series estacionarias
 - 13.6.3. Eliminar tendencia y seasonality
 - 13.6.4. Diferencias
 - 13.6.5. Prueba de Aumented Dicky Fuller
 - 13.7. Modelos de series de tiempo
 - 13.7.1. Modelos AR
 - 13.7.2. Modelos MA
 - 13.7.3. Modelos
 - 13.7.4. Modelos de media móvil
 - 13.7.5. Modelos ARMA y ARIMA
 - 13.7.6. LSTM
 - 13.8. Evaluación de modelos en series de tiempo
 - 13.8.1. Backtesting
 - 13.8.2. Métricas
 - 13.8.3. Visualización de errores

4. Descripción del curso

En este curso de Deep Learning, se cubrirán una variedad de temas que van desde la preparación de datos hasta modelos más avanzados como redes neuronales convolucionales y recurrentes. A continuación, se describen algunos de los temas principales que se abordarán en el curso.

En primer lugar, se discutirá la importancia de la preparación de datos y cómo es fundamental para el éxito del modelo de aprendizaje profundo. La exploración y preprocesamiento de datos serán cubiertos en detalle, incluyendo la visualización de datos para obtener una comprensión más profunda de los patrones y distribuciones de los mismos. Después, se explorarán técnicas para manejar conjuntos de datos desbalanceados, como undersampling, oversampling, Smote y muestras ponderadas. También se discutirán las técnicas para crear nuevas características y cómo convertir problemas de regresión en clasificación. La reducción de la dimensionalidad mediante PCA y la regularización L1 y L2 se cubrirán para mostrar cómo estos métodos pueden mejorar el rendimiento del modelo y prevenir el sobreajuste. Además, se discutirán las máquinas de vectores de soporte y sus variantes de margen duro y margen suave.

Los algoritmos de ensamble también se abordarán en el curso, incluyendo Bagging, Boosting y Random Forests. También se explorará XGboost y su uso en problemas de clasificación. A continuación, se presentarán temas de aprendizaje no supervisado, incluyendo técnicas de distancias, clustering jerárquico y no jerárquico, como K-means. El enfoque principal del curso serán las redes neuronales, empezando por los fundamentos del Perceptrón y avanzando a Perceptrón multicapa y algoritmos de Propagación hacia atrás. Se cubrirán los fundamentos de las Redes Feed Forward y las funciones de activación y costo. También se discutirán técnicas de regularización, como L1 y L2, así como la técnica de Dropout. Se presentarán técnicas de validación y testeo, y se explorarán métodos para ajustar hiperparámetros en el modelo. En particular, el curso cubrirá los tipos de MLP, como clasificación binaria, multclasificación y regresión. Luego, se discutirán las redes neuronales convolucionales y su aplicación a imágenes, incluyendo convolución, kernels, MaxPool y AvgPool, imágenes aumentadas y transfer learning.

Por último, se discutirán las redes neuronales recurrentes, como LSTM, y su aplicación en series de tiempo. Se abordará la manipulación y visualización de series de tiempo, así como las técnicas de preprocesamiento como el inventariado, retrasos, remuestreo, eliminación de tendencia y seasonality, diferencias y la prueba de Aumented Dicky Fuller. También se presentarán los modelos de series de tiempo, incluyendo AR, MA, modelos de media móvil, ARMA y ARIMA, así como LSTM. Se explorarán métodos de evaluación de modelos en series de tiempo, como el backtesting y las métricas, así como la visualización de errores.

En conclusión, este curso de Deep Learning cubre una amplia variedad de temas desde la preparación y exploración de datos, hasta la creación y entrenamiento de modelos complejos de redes neuronales, incluyendo

aplicaciones en series de tiempo y procesamiento de imágenes. A través de este curso, los estudiantes tendrán una comprensión profunda de las técnicas y herramientas utilizadas en Deep Learning, y estarán preparados para aplicar estos conocimientos en diversos campos, desde la industria hasta la investigación. Con una base sólida en la teoría y práctica del Deep Learning, los estudiantes estarán equipados para abordar problemas complejos y encontrar soluciones innovadoras utilizando esta tecnología avanzada (Bishop, 2006).

Referencias

- Bishop, Christopher M. (2006). *Pattern recognition and machine learning*. Springer.
- Duda, Richard O. y Peter E. Hart (1973). *Pattern classification*. John Wiley & Sons.
- Goodfellow, Ian, Yoshua Bengio y Aaron Courville (2016). *Deep learning*. MIT Press.
- Murphy, Kevin P. (2012). *Machine learning: A probabilistic perspective*. MIT Press.