Resumen

Deep Learning

Marco Teran
Universidad Sergio Arboleda

2023

Contenido

¿Por qué usar redes neuronales?

- Disponibilidad de datos para entrenar redes.
- Capacidad computacional a menor costo y con mayor disponibilidad.
- Mejores algoritmos de entrenamiento.
- Gran comunidad que constantemente comparte desarrollos, nuevas arquitecturas o nuevas aplicaciones.
- APIs flexibles, simples y gratuitos.

Frameworks de Deep Learning

Frameworks de Bajo Nivel

Frameworks de Alto Nivel

Keras API

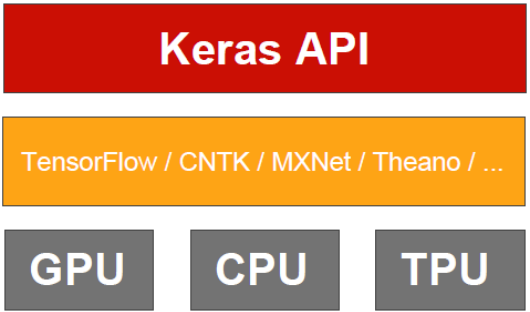

Keras

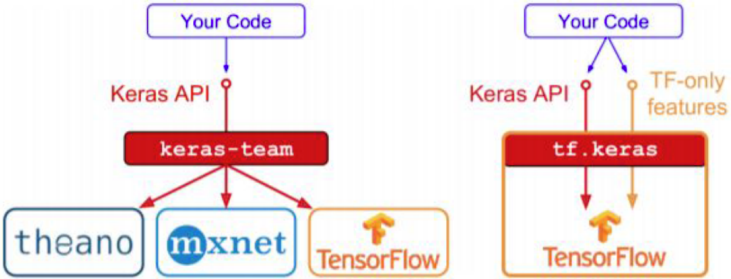
Your Code
Keras API
keras-team
theano
mxnet
TensorFlow
Your Code
Keras API
TF-only features
tf.keras
TensorFlow

Comparativo Frameworks

Framework/ Initial Release	Creadores	Escrito en qué Lenguaje?	Open Source	Soporta CUDA?	Desarrollo activo?	Modelos Preentrenados?
TensorFlow / 2015	Google Brain	C++, Python	Si	Si	Si	Si
Keras / 2015	Francois Chollet	Python	Si	Si	Si	Si
PyTorch / 2016	Facebook	Python, C	Si	Si	Si	Si
Caffe / 2016	Berkeley AI Research	C++	Si	Si	Si	Si
Theano/ 2007	Université de Montréal	C++/ Open CL	Si	Si	No	No
MATLAB+ Deep Learning Toolbox / 2016	MathWorks	MATLAB	No	Si	Si	Si

The Sequential API

```
import keras
from keras import layers

model = keras.Sequential()
model.add(layers.Dense(20, activation='relu', input_shape=(10,)))
model.add(layers.Dense(20, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))

model.fit(x, y, epochs=10, batch_size=32)
```

Estructura de redes neuronales

Perceptrón

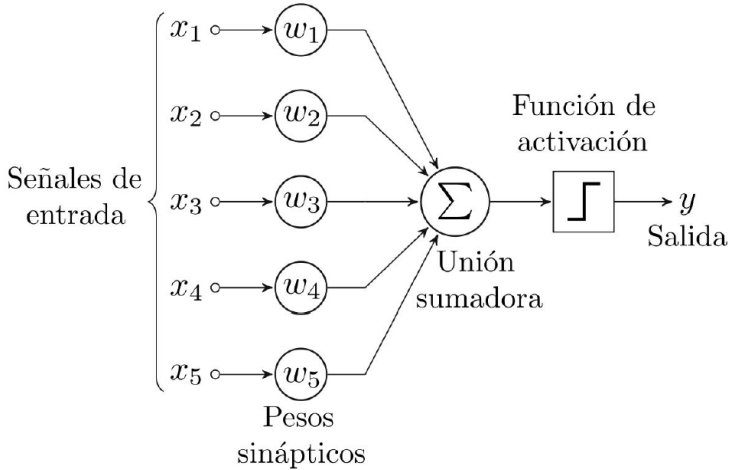
x_1
x_2
x_3
x_4
x_5
w_1
w_2
w_3
w_4
w_5
Señales de entrada
Pesos sinápticos
Unión sumadora
Función de activación
y
Salida

Multi-Layer Perceptron

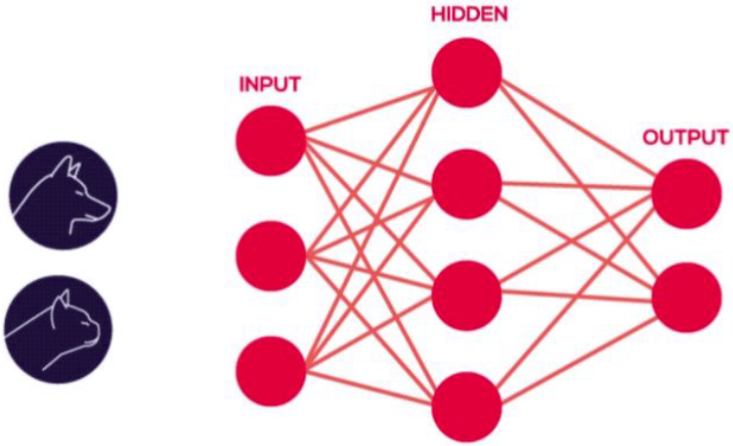

Comparación de funciones de pérdidas

Función de Pérdidas	Operación Residual	Robusto frente a Outliers
MAE (Mean Absolute Error)	Valor Absoluto	Si
MSE (Mean Squared Error)	Cuadrado	No
MAPE (Mean Absolute Percentage Error)	Valor Absoluto	Si

Gradiente descendiente

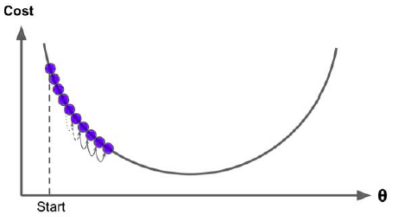

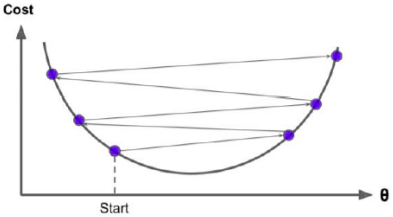

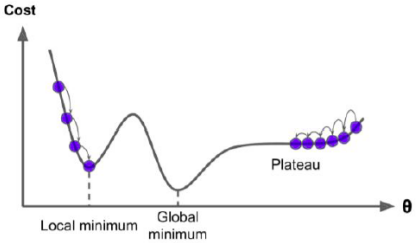

CNN

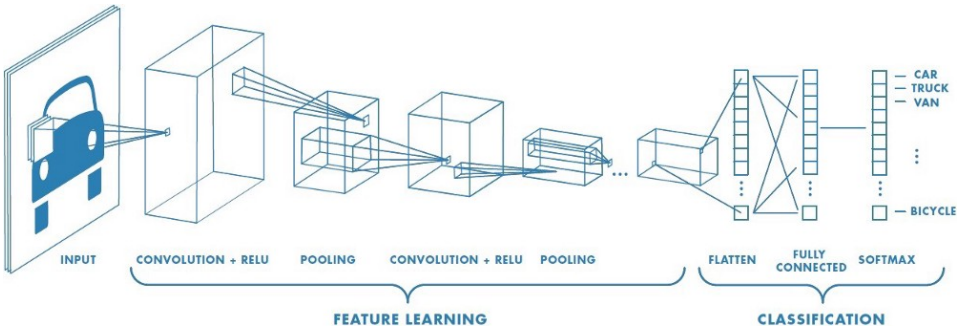
CAR
TRUCK
VAN
BICYCLE
INPUT
CONVOLUTION + RELU
POOLING
CONVOLUTION + RELU
POOLING
FLATTEN
FULLY CONNECTED
SOFTMAX
FEATURE LEARNING
CLASSIFICATION

RNN

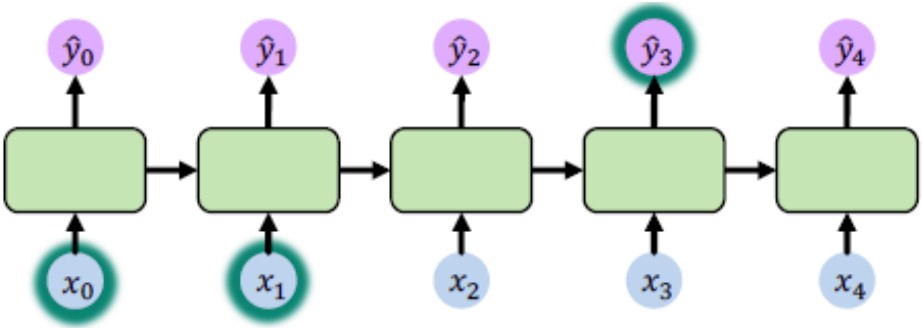

GAN

El **generador** convierte el ruido en una imitación de los datos para tratar de engañar al discriminador.

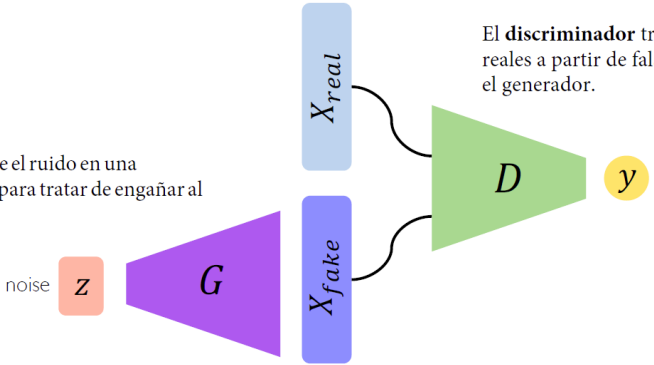

El **discriminador** trata de identificar datos reales a partir de falsificaciones creadas por el generador.

Ajuste de redes neuronales: hiper-parámetros

Número Capas y Neuronas por Capa

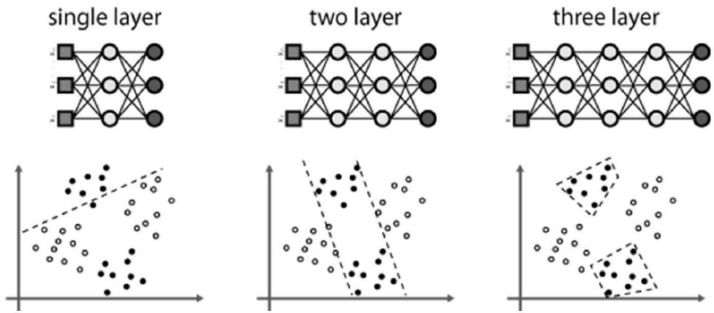

Cantidad Neuronas por Capa = Potencia de 2 más cercana a 2^* (Número de entradas)

$$Para\ 30\ entradas \longmapsto 2 * 30 = 60 \longmapsto 2^6 = \mathbf{64}$$

Épocas e Inicializadores

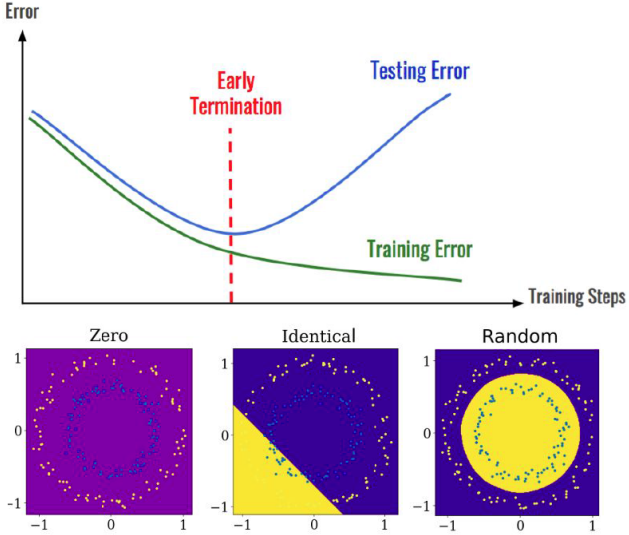

Tasa de Aprendizaje

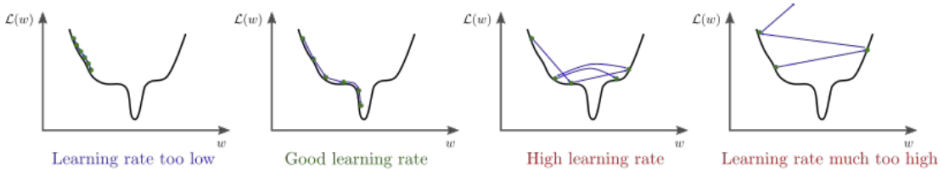

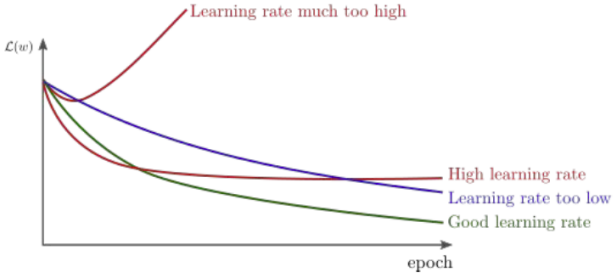

Función de activación y pérdidas

Tipo de Problema	Tipo de salida	Función de activación final	Función de pérdidas
Regresión	Valor Numérico	Linear	Mean Squared Error (MSE)
Clasificación	Salida Binaria	Sigmoid	Binary Cross Entropy
Clasificación	Única etiqueta, multiples clases	Softmax	Cross Entropy
Clasificación	Multiples etiquetas, multiples clases	Sigmoid	Binary Cross Entropy

Transferencia de aprendizaje y aumentación de datos

Aumentación de datos

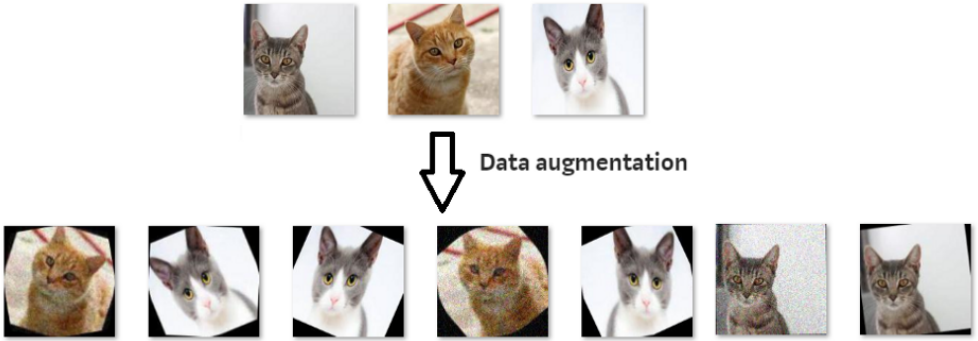

Transferencia de aprendizaje

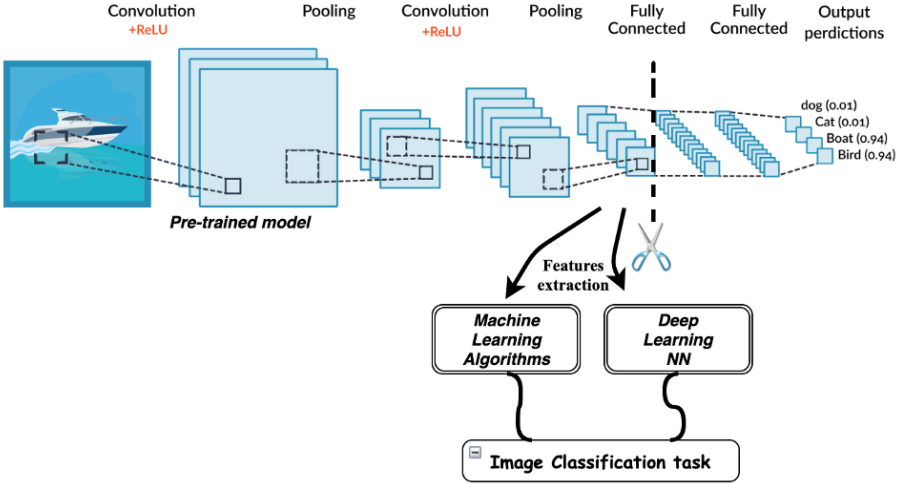

¡Muchas gracias por su atención!

¿Preguntas?

Contacto: Marco Teran
webpage: marcoteran.github.io/
e-mail: marco.teran@usa.edu.co

UNIVERSIDAD
SERGIO ARBOLEDA